





Introdução ao ambiente R

Luciana Souto Mofatto

R

O <u>Rato Roeu a Roupa do Rei de Roma.</u>

A <u>Rainha de Raiva Rasgou o Resto.</u>



O que é <u>R</u>?

R project for Statistical Computing (http://www.r-project.org/)

- Software livre
- Multiplataforma
- Linguagem de programação
- Computação de dados estatísticos
- Criação de gráficos



Conceitos Básicos

Tipos de dados, operadores, comparações, condicionais...

Tipos de dados

- Númericos (numeric)

```
> class(1)
[1] "numeric"
```

- Número Complexo (complex)

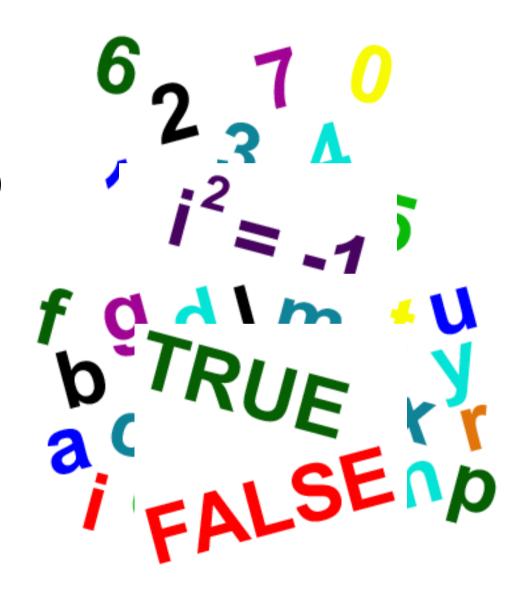
```
> class(1i)
[1] "complex"
```

- Caracteres (character)

```
> class("aula")
[1] "character"
```

- Lógico (logical)

```
> class(TRUE)
[1] "logical"
```



Operadores



- Soma (+)

> 1 + 1

- Subtração (-)

> 4 - 2
[1] 2

- Multiplicação (*)

> 2*2
[1] 4

- Divisão (/)

> 4/2
[1] 2

- Exponencial (^)

> 2^2
[1] 4

- Raiz quadrada (sqrt)

> sqrt(4)
[1] 2

- Logaritmo (log2, log10)

> log2(20)
[1] 4.321928

> log10(20)
[1] 1.30103

Atribuição de valores e variáveis

- Variável: objeto que é capaz de receber um valor ou uma expressão.

- Símbolos de atribuição: = OU <-

- Exemplos:

```
> x = 1
> x
[1] 1
> y <- 2
> y
[1] 2
```

Prática 1:

- Encontrar a solução para a seguinte equação:

$$x = \frac{(100^2 + \sqrt{4000} - \log_2(345)).250}{230}$$

Solução – Prática 1:

```
> x = ((100^2 + sqrt(4000) - log2(345)) * 250) / 230
> x
[1] 10929.15
> 100^2
[1] 10000
> sqrt(4000)
[1] 63.24555
> log2(345)
[1] 8.430453
> 10000 + 63.24555 - 8.430453
[1] 10054.82
> 10054.82 * 250
[1] 2513705
> 2513705/230
[1] 10929.15
```

Comparação



- Igual (==)

- Menor (<)

- Menor ou igual (<=)

- Maior (>)

- Maior ou igual (>=)

- Diferente (!=)

- E (&)

$$> (x > 0) & (x <= 1)$$
 [1] TRUE

- Ou (|)

$$> (y > 0) | (y < 1)$$
 [1] TRUE

Prática 2

Sabendo que:

$$x = 15;$$

 $y = log10(235);$
 $z = (25)^3$

Quais expressões abaixo são verdadeiras ou falsas?

a)
$$(x + z) >= y$$
?

b)
$$(y + z) <= x^2$$
?

c)
$$log2(z) == (x + y)$$
?

Solução – Prática 2a:

```
> x = 15
> y = log10(235)
> z = 25^3

> # a) (x + z) >= y

> (x + z) >= y
[1] TRUE

> x + z
[1] 15640
> y
[1] 2.371068
```

Solução – Prática 2b:

```
> x = 15
> y = log10(235)
> z = 25^3

> # b) (y + z) <= x^2

> (y + z) <= x^2
[1] FALSE
> y + z
[1] 15627.37
> x^2
[1] 225

> # C) z == (x + y)
```

Solução – Prática 2c:

```
> x = 15
> y = log10(235)
> z = 25^3

> # c) log2(z) == (x + y)

> log2(z) == (x + y)
[1] FALSE

> log2(z)
[1] 13.93157
> (x + y)
[1] 17.37107
```

Tabela Verdade

Comparação por "E"

Condição 1	Condição 2	(Condição 1) E (Condição 2)
TRUE	TRUE	TRUE
TRUE	FALSE	FALSE
FALSE	TRUE	FALSE
FALSE	FALSE	FALSE

Comparação por "OU"

Condição 1	Condição 2	(Condição 1) OU (Condição 2)
TRUE	TRUE	TRUE
TRUE	FALSE	TRUE
FALSE	TRUE	TRUE
FALSE	FALSE	FALSE

Condicional

```
- Se (if)
> x = 5
> if(x > 1){
+ x
+ }
[1] 5
- Senão (else)
> x <- 2
> y <- 1
> if(x < y) {
+ X
+ } else {
+ y
+ }
[1] 1
```

```
if (condição) {
} else {
```

Prática 3

Sabendo que:

$$x = 26^{3} - (12*10)^{2};$$

$$y = \log 2(234.5) + (23*16)/100;$$

$$z = 100 - 9^{2} + 12^{3}$$

Quais expressões são verdadeiras?

a) Se
$$((x > y) AND (z <= x)) \{ x = 1 \} senão \{ x = 0 \}?$$

b) Se
$$((x + z) > 10 \text{ OR } (x + y) == (z - x)) \{ x = 1 \} \text{ senão} \{ x = 0 \}$$
?

c) Se(
$$(z >= x)$$
 AND $(y >= x)$){ $x = 1$ } senão{ $x = 0$ }?

Solução – Prática 3a:

```
> x = 26^3 - (12*10)^2; > if((x > y) && (z <= x)){
> y = log2(234.5) + (23*16)/100; + x = 1
> z = 100 - 9^2 + 12^3
> # a) (x > y) && (z <= x)
> (x > y) && (z <= x)
[1] TRUE
> (x > y)
[1] TRUE
> (z \le x)
[1] TRUE
> X
[1] 3176
> y
[1] 11.55344
> z
[1] 1747
```

```
+ } else {
      + x = 0
      + }
       >
       > x
       [1] 1
```

Solução – Prática 3b:

```
> x = 26^3 - (12*10)^2;
> y = log2(234.5) + (23*16)/100; == (z - x))
> z = 100 - 9^2 + 12^3
> # b) ((x + z) > 10) | ((x + y) + x = 0
== (z - x)
> ((x + z) > 10) | ((x + y) == [1] 1
(z - x)
[1] TRUE
> x + z > 10
[1] TRUE
> x + z
[1] 4923
> ((x + y) == (z - x))
[1] FALSE
> x + y
[1] 3187.553
> z - x
[1] -1429
```

```
> if(((x + z) > 10) || ((x + y)
        + x = 1
         + } else {
          + }
          > x
```

Solução – Prática 3c:

```
> x = 26^3 - (12*10)^2; > if((z >= x) && (y >= x)){}
> y = log2(234.5) + (23*16)/100; + x = 1
> z = 100 - 9^2 + 12^3
> \# C) (z >= x) && (y >= x) + 
> (z >= x) && (y >= x)
[1] FALSE
> (z >= x)
[1] FALSE
> (y >= x)
[1] FALSE
> z
[1] 1747
> x
[1] 3176
> y
[1] 11.55344
```

```
+ } else {
+ x = 0
  > x
  [1] 0
```

Conceitos Intermediários

Objetos e suas funções, iterações





Objetos - Vector

<u>Vector</u>: lista de elementos. Tipos: *numeric, character, logical*

```
> a = c(1,2,3,4,5,6)
> b = c("one","two","three", "four", "five","six")
> c = c(TRUE,FALSE,TRUE,FALSE,TRUE,FALSE)
> d = vector(mode = "numeric", length = 10)
```

Aceita operações de:

- Soma, subtração, divisão, multiplicação...

Objetos - Vector

Mais operações:

```
> x = c(9,8,7,6,5,4,3,2,1,0)
> length(x) #tamanho do vector
[1] 10
> x[4] # imprime o quarto elemento do vector
[1] 6
> x[1:3] # imprime na tela os elementos 1 a 3
[1] 9 8 7
> head(x) # imprime os 6 primeiros elementos do vector
[1] 9 8 7 6 5 4
> tail(x) # imprime os 6 últimos elementos do vector
[1] 5 4 3 2 1 0
```

Iteração (loop)

For:

```
> x = c(9,8,7,6,5,4,3,2,1,0)
> a = vector(mode =
"numeric",length=length(x))

> for(i in 1:length(x)){
+ a[i]=x[i]+ 1
+ }
>
> a
[1] 10 9 8 7 6 5 4 3 2 1
```

While:

```
> x = c(9,8,7,6,5,4,3,2,1,0)
> a = vector(mode =
"numeric",length=length(x))
> i = 1

> while(i <= length(x)){
+ a[i] = x[i] + 1
+ i = i + 1
+ }
> a
[1] 10 9 8 7 6 5 4 3 2 1
```

Prática 4

Sabendo que:

$$a = c(10,2,3,14,34,200,40)$$

 $b = c(0,23,65,93,72,10,11,90)$

Calcule:

- a) Quais os tamanhos de cada *vector*?
- b) Quais os valores das somas dos primeiros 4 elementos de cada *vector*?
- c) E se somar os primeiros 4 elementos de a com os 4 últimos elementos de b, qual seria o valor?

Solução - Prática 4a e 4b

```
> a = c(10, 2, 3, 14, 34, 200, 40)
> b = c(0,23,65,93,72,10,11,90)
> # a) length(a); length(b)
> length(a)
[1] 7
> length(b)
[1] 8
> # b) soma dos primeiros 4 elementos de cada vector
> soma a = 0
> for(i in 1:4){
+ soma_a = soma_a + a[i]
+ }
> soma a
[1] 29
> soma b = 0
> for(i in 1:){
+ soma_b = soma_b + b[i]
+ }
> soma b
[1] 181
```

Solução – Prática 4c

```
> a = c(10,2,3,14,34,200,40)
> b = c(0,23,65,93,72,10,11,90)

> # b) soma dos primeiros 4 elementos de a e 4 ultimos de b
> sum(a[1:4]) + sum(b[5:8])
[1] 212

> sum(a[1:4])
[1] 29

> sum(b[5:8])
[1] 183

> 29 + 183
[1] 212
```

Objetos - Matrix

<u>Matriz</u>: são estruturas bi-dimensionais utilizadas para armazenar dados de um tipo.

matriz[linha, coluna]

```
> w = cbind(a,b,c) #criacao de uma matriz a partir de 3 vectors
> W
    a b c
[1,] "1" "one" "TRUE"
[2,] "2" "two" "FALSE"
[3,] "3" "three" "TRUE"
[4,] "4" "four" "FALSE"
[5,] "5" "five" "TRUE"
[6,] "6" "six" "FALSE"
> w[, "a"]
[1] "1" "2" "3" "4" "5" "6"
> w[1,]
        b
   а
  "1" "one" "TRUE"
```

Prática 5

Considere a matriz de 3 colunas e 7 linhas:

```
m = cbind(a = c(100,122,33,54,64,20,4),
b = c(40,123,55,67,21,18,12),
c = c(12,21,44,23,87,50,123))
```

Calcule:

A média e a mediana dos elementos da coluna "a","b" e "c" e concatene em uma nova matriz.

(Dica: utilize os comandos mean e median para média e mediana)

Solução - Prática 5

```
> m = cbind(a = c(100, 122, 33, 54, 64, 20, 4),
+ b = c(40, 123, 55, 67, 21, 18, 12),
+ c = c(12, 21, 44, 23, 87, 50, 123))
>
> media = c(mean(m[,"a"]), mean(m[,"b"]), mean(m[,"c"]))
> mediana = c(median(m[,"a"]), median(m[,"b"]), median(m[,"c"]))
>
> d = cbind(media, mediana)
> d
        media mediana
[1,] 56.71429
                    54
[2,] 48.00000
                    40
[3,] 51.42857
                    44
```

Objetos - List

<u>Lista</u>: conjunto ordenado de objetos, os quais podem conter valores de diferentes tipos de dados ou outros objetos.

```
> class(list_samples)
[1] "list" list_samples = list( name = "Sample01", group = "Control",
no.replicates = 3, time = c( 1, 2, 3))
```

Operações de List:

```
> list_samples
$name
[1] "Sample01"
$group
[1] "Control"
$no.replicates
[1] 3
$time
[1] 1 2 3
```

Objetos - List

Acesso aos dados:

```
> ### Nome dos campos
                                     > ### Index dos campos
> list samples$name
                                     > list samples[[1]]
[1] "Sample01"
                                     [1] "Sample01"
> list samples$group
                                     > list_samples[[2]]
[1] "Control"
                                     [1] "Control"
> list samples$no.replicates
                                     > list samples[[3]]
[1] 3
                                     [1] 3
> list_samples$time # 3 elementos
                                     > list_samples[[4]] # 3 elementos
[1] 1 2 3
                                     [1] 1 2 3
> list_samples$time[1]
                                     > list_samples[[4]][1]
[1] 1
                                     [1] 1
> list_samples$time[2]
                                     > list_samples[[4]][2]
[1] 2
                                     [1] 2
> list samples$time[3]
                                     > list_samples[[4]][3]
[1] 3
                                     [1] 3
```

Ou:

Prática 6

Faça listas contendo dados de 2 experimentos:

- a) Lista 1 = experimento da amostra 1 do grupo "controle" com 3 réplicas biológicas e tempos de 24 e 72 horas;
- b) Lista 2 = experimento da amostra 2 do grupo "teste" com somente uma réplica e tempos de 1, 2 e 3 horas.

Solução - Prática 6

```
> list2 =
> list1 = list(name="Amostra1",
group="Controle", nro.replicas=3,
                                      list(name="Amostra2", group="Teste
                                      ", nro.replicas=1, time=c(1, 2, 3))
time=c(24,72))
>
> list1
                                      > list.2
                                      $name
$name
                                      [1] "Amostra2"
[1] "Amostra1"
                                      $group
$group
                                      [1] "Teste"
[1] "Controle"
$nro.replicas
                                      $nro.replicas
                                      [1] 1
[1] 3
                                      $time
$time
                                      [1] 1 2 3
[1] 24 72
```

Objetos - Data frame

Permite vários tipos de dados, contando que todas colunas tenham o mesmo número de linhas.

```
> df = data.frame(
gene_id = c("MT-CO1", "COL1A2", "COL1A1", "FTH1", "FN1", "MT-
TF", "VIM", "EEF1A1", "THBS1", "GREM1"),
read_count_s1 = c(10,2,15,13,19,22,0,0,0,200),
read_count_s2 = c(50,0,0,0,0,111,12,9,10,300))
> class(df)
[1] "data.frame"
```

Objetos - Data frame

Operações de um data frame:

```
> row.names(df) = df$gene_id #dar nome às linhas de um data.frame
> head(df) # imprime as 6 primeiras linhas do vector
       gene_id read_count_s1 read_count_s2
MT-CO1 MT-CO1
                         10
                                       50
COL1A2 COL1A2
COL1A1 COL1A1
                         15
FTH1 FTH1
                         13
                         19
FN1
        FN1
                         2.2.
MT-TF MT-TF
                                     111
```

Objetos - Data frame

Mais operações de um data frame:

```
> df["FN1",] # imprime somente a linha chamada "C"
   gene id read count s1 read count s2
       FN1
FN1
                      19
> df[2:5,] # imprime as linhas 2 a 5
      gene_id read_count_s1 read_count_s2
COL1A2 COL1A2
COL1A1 COL1A1
                         15
FTH1 FTH1
                         13
FN1
          FN1
                         19
> dim(df) # imprime as dimensões de um data.frame
[1] 10 3
```

Prática 7

Considere:

```
genes = c("a","b","c","d");
read_count_amostra1 = c(100,120,0,12);
read_count_amostra2 = c(12,90,20,0);
read_count_amostra3 = c(23,45,67,33)
```

Criar um *dataframe* que contenha os dados acima, também calculando os valores de soma dos *read counts* para cada gene.

Solução – Prática 7

```
> genes = c("a", "b", "c", "d");
> read_count_amostra1 = c(100,120,0,12);
> read count amostra2 = c(12,90,20,0);
> read count amostra3 = c(23,45,67,33)
> soma rc = 0
> for(i in 1:length(genes)){
+ soma rc[i] = read count_amostra1[i] + read_count_amostra2[i] +
read count amostra3[i]
+ }
> soma rc
[1] 135 255 87 45
> df =
data.frame(read_count_amostra1, read_count_amostra2, read_count_amostra
3, soma rc, row.names=genes)
```

Solução – Prática 7

```
> df =
data.frame(read_count_amostra1, read_count_amostra2, read_count_amostra
3, soma_rc, row.names=genes)
> df
  read_count_amostra1 read_count_amostra2 read_count_amostra3 soma_rc
                   100
                                          12
                                                               23
                                                                       135
а
                                          90
                                                                       255
                   120
                                                               45
b
                                          20
                                                               67
                                                                        87
                     ()
С
d
                    12
                                           0
                                                               33
                                                                        45
```

Conceitos Avançados

Manipulação de arquivos





Importar e Manipular Arquivos

R pode importar arquivos de tabelas Excel, txt (" \t''), csv (",").

```
> getwd() #mostra o diretorio de trabalho atual
[1] "/Users/Teste"
> setwd("/Users/Teste/tables") #altera o diretorio de trabalho
> table01 = read.table( file = "text table01.txt", sep = "\t",
header = TRUE)
> row.names(table01) = table01$Alunos
> table01 = table01[,2:4]
> names(table01)
[1] "Disciplina A" "Disciplina B" "Disciplina C"
> head(table01)
      Disciplina_A Disciplina_B Disciplina_C
Aluno01 A
             10.0
                     \Box
Aluno02 A
             7.5
                     В
Aluno03 B 8.5 A
Aluno04 B 4.5 A
Aluno05 A 2.0
                    В
Aluno06 D 5.0 A
```

Importar e Manipular Arquivos

```
> # Comando que cria um subconjunto com notas = A na Disciplina A
> notas A = subset(table01, Disciplina A = "A")
> head(notas A)
      Disciplina_A Disciplina_B Disciplina_C
              10.0
Aluno01 A
                     \Box
Aluno02 A
          7.5
                     В
Aluno05 A 2.0 B
Aluno08 A 6.7 A
Aluno13 A 9.0 C
> class(notas A)
[1] "data.frame"
> # Comando que calcula a média de notas da Disciplina B
> mean(table01$Disciplina B)
[1] 7.3
> # Comando para salvar uma tabela em um arquivo formato texto
> write.table(notas A, file="text table01 notas A discA.txt",
row.names=TRUE)
```

Prática 8

Antes de começar:

- Criar um dataframe:

```
> genes =
c("GAPDH","COL12A1","ACTB","ANXA2","SOD2","MMP2","FSTL1","IGFBP4","A
HNAK","COL8A1")
> rc_sample1 = c(1200,3425,23987,567,789,342,555,678,444,231)
> rc_sample2 = c(5050,978,349,954,565,4787,344,66,737,100)
> rc_sample3 = c(230,4646,5858,3432,567,8382,453,2020,100,102)
> df = data.frame(rc_sample1,rc_sample2,rc_sample3,row.names=genes)
```

-Salvar o dataframe em um arquivo:

```
> write.table(df, file = "arquivo_pratica8.txt",sep="\t")
```

Prática 8

- Abrir o arquivo "arquivo_pratica8.txt", calcular a média e a mediana por gene.
- Criar outro dataframe contendo:
 - Todos os read counts por gene
 - Todas as médias por gene
 - Todas as medianas por gene
- Salvar o novo dataframe como "arquivo2_pratica8.txt" separado por tabulação.

Dica:

- Calcular a média usando:

```
mean(c(x$rc_sample1, x$rc_sample2, x$rc_sample3))
```

- Calcular mediana usando:

```
median(c(x$rc_sample1,x$rc_sample2,x$rc_sample3))
```

Solução - Prática 8

```
> tabela = read.delim(file = "arquivo pratica8.txt", header = TRUE)
> head(tabela)
       rc_sample1 rc_sample2 rc_sample3
            1200
                       5050
                                  230
GAPDH
                       978
                                 4646
COL12A1
            3425
ACTB
        23987
                       349 5858
           567
ANXA2
                       954
                                3432
           789 565 567
SOD2
             342
                    4787
                                 8382
MMP2
> media = 0; mediana = 0;
> for(i in 1:dim(tabela)[1]){
+ media[i] =
mean(c(tabela$rc_sample1[i],tabela$rc_sample2[i],tabela$rc_sample3[i]))
+ mediana[i] =
median(c(tabela$rc_sample1[i],tabela$rc_sample2[i],tabela$rc_sample3[i]))
+ }
> novo df = data.frame(df, media, mediana)
>
```

Solução – Prática 8

> head(novo_df)

```
rc_sample1 rc_sample2 rc_sample3 media mediana
GAPDH
           1200
                   5050
                           230 2160.0000
                                           1200
COL12A1
          3425
                    978
                          4646 3016.3333
                                           3425
         23987
                    349 5858 10064.6667 5858
ACTB
           567
                    954 3432 1651.0000 954
ANXA2
           789
                    565
                           567 640.3333 567
SOD2
           342 4787 8382 4503.6667
MMP2
                                           4787
```

> write.table(novo_df,file="arquivo2_pratica8.txt",sep="\t")

HELP!!!

> ?mean
starting httpd help server ... done

mean {base} R Documentation Arithmetic Mean Description Generic function for the (trimmed) arithmetic mean. Usage mean(x, ...) ## Default S3 method: mean(x, trim = 0, na.rm = FALSE, ...) Arguments An R object. Currently there are methods for numeric/logical vectors and date, date-time and time interval objects. Complex vectors are allowed for trim = 0, only. trim the fraction (0 to 0.5) of observations to be trimmed from each end of x before the mean is computed. Values of trim outside that range are taken as the nearest endpoint. na · rm a logical value indicating whether NA values should be stripped before the computation proceeds. further arguments passed to or from other methods. Value If trim is zero (the default), the arithmetic mean of the values in x is computed, as a numeric or complex vector of length one. If x is not logical (coerced to numeric), numeric (including integer) or complex, NA real is returned, with a warning. If trim is non-zero, a symmetrically trimmed mean is computed with a fraction of trim observations deleted from each end before the mean is computed. References Becker, R. A., Chambers, J. M. and Wilks, A. R. (1988) The New S Language. Wadsworth & Brooks/Cole. See Also weighted.mean, mean.POSIXct, colMeans for row and column means

http://www.r-project.org/



About R

What is R?

Contributors

Screenshots

What's new?

Download, Packages

CRAN

R Project

Foundation

Members & Donors

Mailing Lists

Bug Tracking

Developer Page

Conferences

Search

Documentation

Manuals

FAQS

The R Journal

Wiki

Books

Certification

Other

Misc

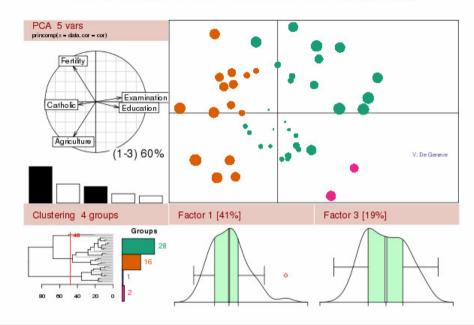
Bioconductor

Related Projects

User Groups

Links

The R Project for Statistical Computing



Getting Started:

- R is a free software environment for statistical computing and graphics. It compiles and runs on a wide variety of UNIX platforms, Windows and MacOS.
 To download R, please choose your preferred <u>CRAN mirror</u>.
- If you have questions about R like how to download and install the software, or what the license terms are, please read our <u>answers to frequently asked</u> <u>questions</u> before you send an email.

News:

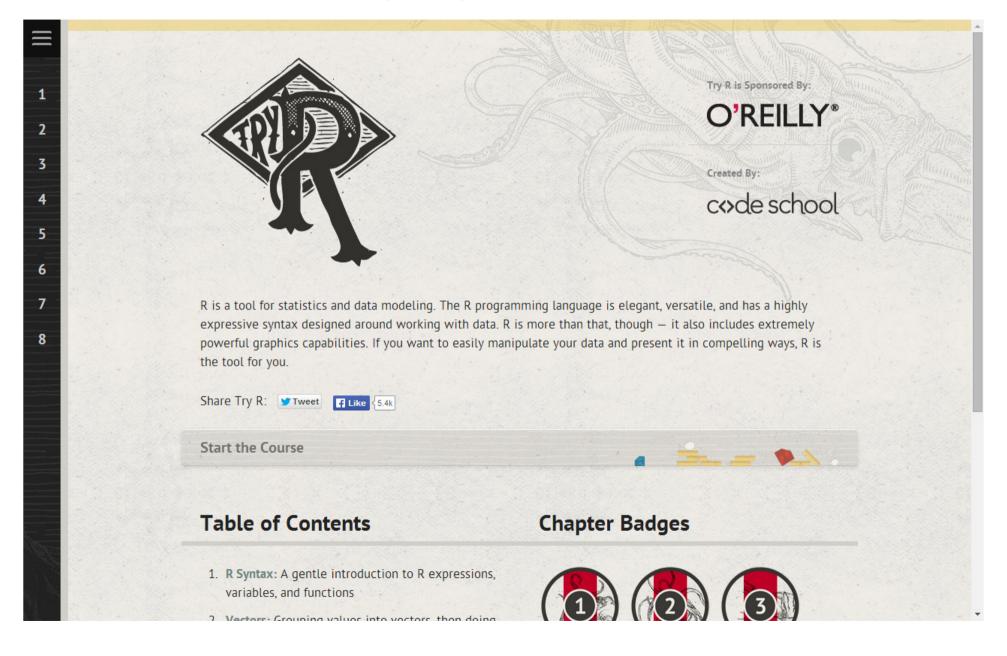
- The R Journal Volume 6/2 is available.
- R version 3.1.2 (Pumpkin Helmet) has been released on 2014-10-31.
- useR! 2014, took place at the University of California, Los Angeles, USA June 30 July 3, 2014.
- R version 3.0.3 (Warm Puppy) has been released on 2014-03-06.
- useR! 2015, will take place at the University of Aalborg, Denmark, June 30 July 3, 2015.

This server is hosted by the Institute for Statistics and Mathematics of WU (Wirtschaftsuniversität Wien).

http://www.statmethods.net/interface/index.html



http://tryr.codeschool.com/



https://www.datacamp.com/courses/introduction-to-r/

